融合新型內容相依時序方向模型入侵偵測與任務導向檢索增強稽核之 AI 資安框架



從流量判定，走到有證據、可回復的處置。

★ 原創：CTBM、校準融合、任務導向檢索、本機 AI 稽核、受控回復 | 引用：PBCNN（Yu et al., 2021）

偵測
17 類互補判定

檢索
Top-5 訓練案例

稽核
本機 AI 三態

回復
讀回 + 到期回復

影片展示

一次 HTTP 洪流，從封包到處置｜互動展示實錄 30 秒



通過策略才將指令送向 **r1**；證據不足則走人工複核路徑。

一個框架，四個連續階段

01 前處理張量 流量表徵

真實前處理張量
遮罩欄位 · 流量切窗

三種線索

內容 | 時間差 | 方向

↓

流量表徵
送入兩個互補模型

02 CTBM + PBCNN 互補判定

CTBM
內容 · 時間差 · 方向

PBCNN
短窗位元組模式 · 既有模型

校準 + OOF Gate
依事件證據融合

↓

17 類正式判定
信心 + 512 維表徵

03 Top-5 + 本機 AI 證據稽核

529 維任務向量
512 表徵 + 17 機率 · L2

↓

Top-5 相似案例
1 2 3 4 5 訓練庫

↓

本機 AI 稽核

支持 | 複核 | 不確定

04 策略·讀回·到期 受控回復

策略檢查

↓

套用規則

↓

讀回驗證

↓

到期回復

複核 / 不確定 → 監測或蒐證

同一事件 ID 串起 正式判定 · Top-5 證據 · AI 稽核結論 · 處置回條

互補模型，形成同一次判定

同一流量輸入

封包內容

時間差

方向

CTBM

本團隊設計

內容 · 時序 · 方向

讀取流量的時序關係

PBCNN

引用既有模型

短窗位元組模式

補充局部內容特徵

校準 + OOF Gate

依事件證據融合

形成同一次正式判定 · 本團隊設計

Macro-F1 93.05% 見第 07 頁

17 類判定 + 校準信心 + 模型表徵 → 後段檢索與稽核

兩個模型讀同一筆流量：CTBM（本團隊設計）看時序與方向，PBCNN（引用既有模型，Yu et al., 2021）看短窗位元組，再由 Gate 依證據融合。

EVIDENCE

把偵測表徵，變成可核對的證據

STEP 01

組合任務向量

512 維表徵

+

17 維類別機率

529 維任務向量

L2 正規化後檢索

STEP 02

找出相似案例

訓練案例庫

1,550 筆案例

1 2 3 4 5

Top-5 相似案例

只檢索訓練資料，依相似度排序

STEP 03

本機 AI 稽核

判定 + 案例證據

核對同一事件

支持 複核 不確定

保留正式分類

稽核結論附回事件紀錄

- **同一事件 ID：分類結果與檢索證據一路可追溯。**

受控執行，留下可回復的處置紀錄

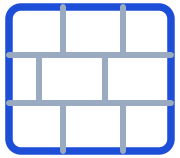
01



政策檢查

範圍 · 允許動作 · 期限

02



套用規則

受允許策略才執行

03



讀回驗證

核對規則與事件回條

04



到期回復

撤銷並確認服務恢復



複核 / 不確定 → 不自動處置，改為監測或蒐證

6 種隔離 TCP 情境

4 種套用規則、2 種監測或蒐證

隔離交易與回復驗證，不等同原生攻擊防禦率

6/6

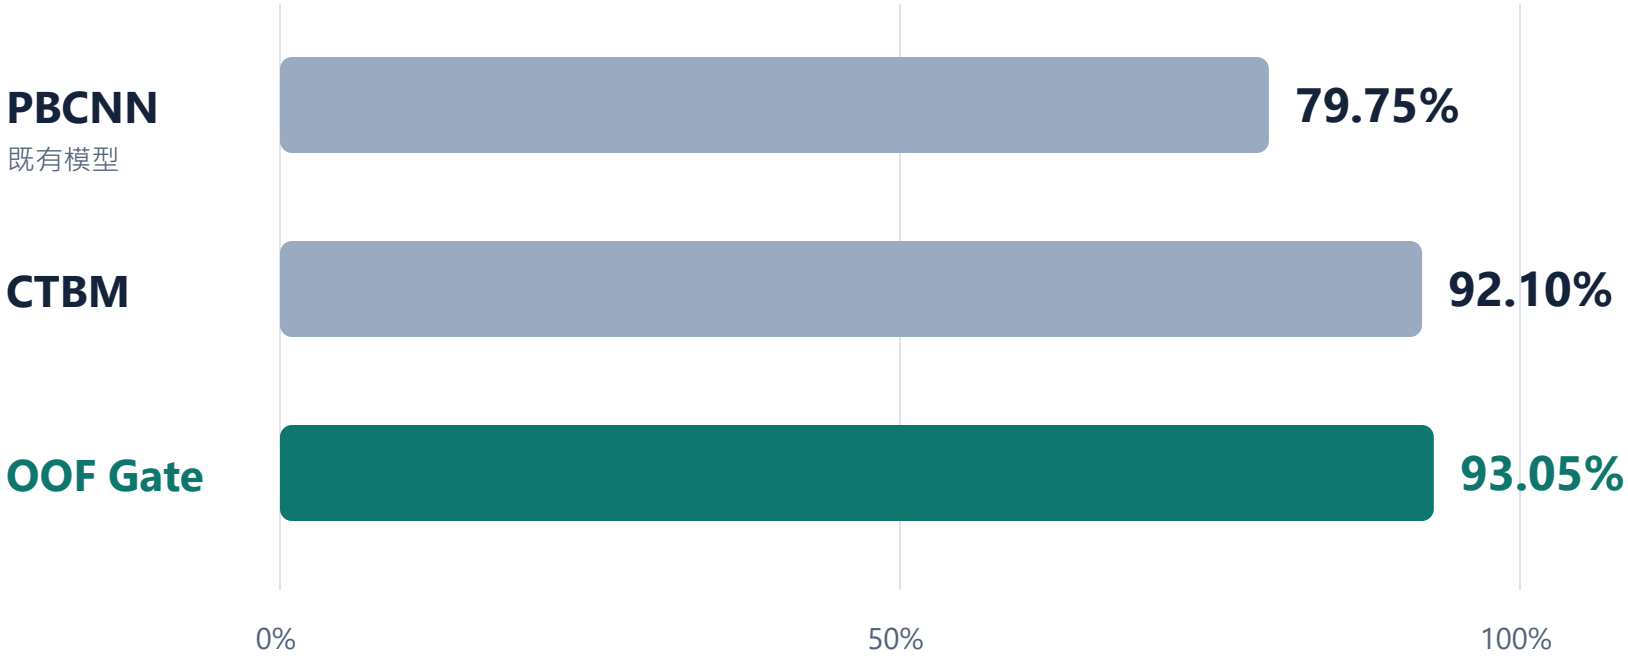
背景服務保留

6/6

到期回復完整

互補融合，提升整體辨識效果

相同 18,998 筆封存測試 · Macro-F1



整體準確率

98.08%

17 類分類 · OOF Gate

同一封存測試集

固定 17 類輸出

融合相較 PBCNN 提升 13.30 個百分點；相較 CTBM 提升 0.95 個百分點。

案例提供證據，AI 完成分流

檢索效果

97.62%

Top-5 命中率

93.89%

MRR@5 排序品質

1,550 案例 / 463 查詢 · 重疊 0



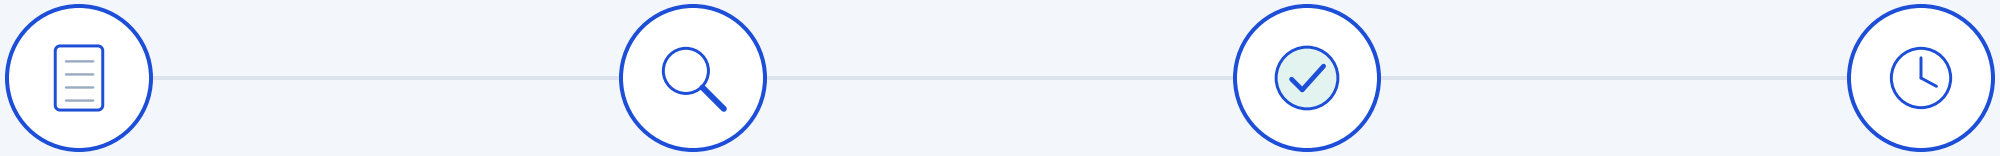
支持精確率 97.11% · 正式分類保持可追溯

18 / 30 筆偵測誤判分流至複核或不確定；其餘 12 筆仍獲支持，處置另經策略檢查。

AI SECURITY FRAMEWORK

一套可展示、可查核的資安框架

偵測有依據，稽核有證據，處置可回復。



正式判定
17 類 + 信心

檢索證據
Top-5 訓練案例

稽核結論
支持 / 複核 / 不確定

處置回條
讀回 + 到期回復

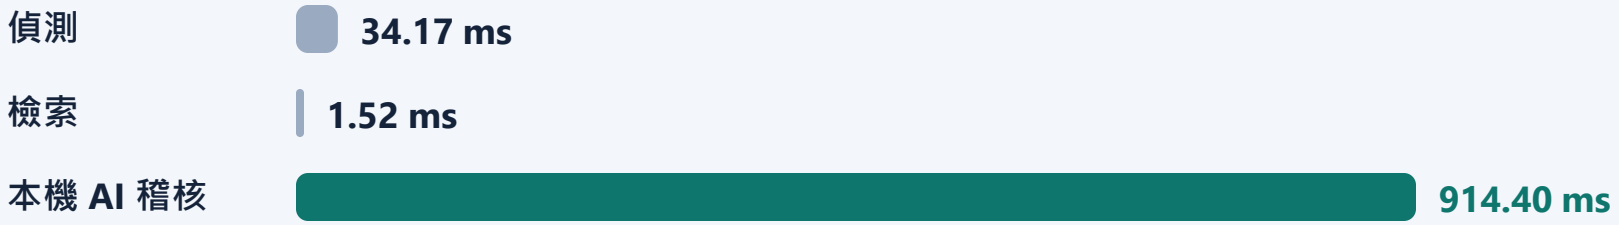
同一事件 ID，串起分類、證據、判斷與回復紀錄。

17 類真實張量重跑 · 6 種隔離 TCP 情境驗證

感謝聆聽，敬請指教。

答詢圖解｜速度與誤判

Q1 一筆告警從進來到產生處置，要花多久？能即時處理嗎？



RTX 4090 暖機後 17 次單筆實測中位數；本機 AI 是主要耗時，非負載或吞吐測試

0.95 秒

單筆中位數合計

Q2 哪一類攻擊最容易判錯？判錯時系統會怎麼做？



Web-BruteForce F1 75.15% 次低；兩類互相混淆最多，證據不足時不自動處置

42.73%

Web-XSS F1（最弱類別）

JUDGES · Q&A

答詢圖解｜處置與 AI 可靠度

Q3 處置會不會影響正常使用者？規則會一直留著嗎？

- 正常類禁止處置
- 動作需符合白名單
- 只限指定來源與服務
- 期限 30–900 秒

隔離實測：設定 30 秒，約 30.1 秒撤銷

背景服務保留 6 / 6、回復完整 6 / 6

策略限定來源、服務與期限；6 種隔離情境到期回復 6 / 6，不等同真實攻擊防禦率

6 / 6

背景服務保留

Q4 本機 AI 會不會亂判（幻覺）？AI 判錯了怎麼辦？

AI 只回三態 JSON → 463 / 463 格式有效 → 正式分類改動 0 筆

錯誤支持 12 筆：6 筆仍只蒐證或被策略擋下

AI 輸入不含真實標籤

支持精確率 97.11%；AI 只附加結論，處置另經策略檢查

0 筆

AI 改寫正式分類

答詢圖解｜新攻擊與導入

Q5 遇到沒看過的新型攻擊怎麼辦？案例庫要怎麼更新？

未見過的攻擊 → Top-5 同類不足或 AI 不確定 → 保留蒐證，人工確認

確認後加入案例庫，不需改 AI 提示

新增類別需重新訓練偵測模型

本次未量測未知攻擊；機制上證據不足即保留人工複核，不自動處置

17 類

目前固定輸出類別

Q6 實際導入一間公司需要什麼？資料會不會外流？

本機工作站 · RTX 4090 · Llama 3 8B · 案例庫

欄位遮罩 → 17 類推論 → 檢索 + AI → 路由器規則

接新來源需轉成相同欄位與表徵；處置以 Mininet 隔離驗證，尚未接企業正式網路

0

外部 API 呼叫